

# MAPSI – Cours 1 : Rappels de probabilités et statistiques

Nicolas Thome & Pierre Henri Wuillemin

LIP6 / ISIR – Sorbonne Université, France

- 1 Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon
- 4 Variables multiples, loi jointe, conditionnelle
- 5 Indépendance probabiliste
- 6 Conclusion

- **MAPSI** : Méthodes et algorithmes de probabilité et statistique en informatique
  - **Code UE** : MU4IN601
- **Calendrier** :  
<https://cal.ufr-info-p6.jussieu.fr/master/>  
⇒ Cocher M1-IMA
- **Ressources sur moodle** :  
<https://moodle-sciences-23.sorbonne-universite.fr/login/index.php>
- Répartition dans les groupes quasi-figée
- Mail & nouvelles fraîches pour les informations de dernière minute
- **Mattermost** (=slack gratuit) pour échanger sur les problèmes scientifiques
  - <http://tiny.cc/M1DAC23> pour s'inscrire
  - Channel MAPSI

## Organisation :


- Cours : théorie & concepts, exemples
- TD : applications & calculs sur feuille
- TME : mise en oeuvre des méthodes sur des exemples concrets

## Notation :

- Examen final : 50%
  - $\approx$  75% questions sur des formulations analytiques + calcul
  - $\approx$  25% questions algo/code
- Partiel : 35%
- Notes de participation (contrôle continu, CC) : 15%
  - Attention : l'essentiel de la note est constitué du travail effectué **durant la séance**
  - **Soumission obligatoire** du code de TME en fin de séance...
  - ... Et **commentaires bienvenus** pour faciliter la correction
- session 2 :  $\max(\text{rattrapage}, 15\% \text{ CC} + 85\% \text{ rattrapage})$


# Pourquoi faire MAPSI ?

- Parce que c'est obligatoire
- Parce que c'est un bon rappel de statistiques pour...
  - Comprendre la littérature scientifique en générale
  - Comprendre comment fonctionne l'analyse de données
- Parce que c'est la porte d'entrée vers les sciences des données !



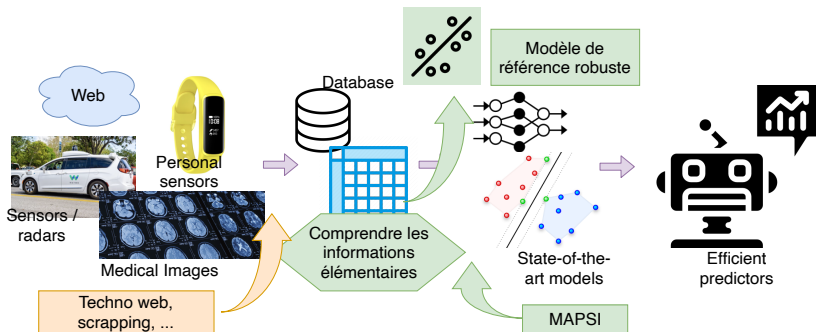
# Pourquoi faire MAPSI ?

- Parce que c'est obligatoire
- Parce que c'est un bon rappel de statistiques pour...
  - Comprendre la littérature scientifique en générale
  - Comprendre comment fonctionne l'analyse de données
- Parce que c'est la porte d'entrée vers les sciences des données !




# Pourquoi faire MAPSI ?

- Parce que c'est obligatoire
- Parce que c'est un bon rappel de statistiques pour...
  - Comprendre la littérature scientifique en générale
  - Comprendre comment fonctionne l'analyse de données
- Parce que c'est la porte d'entrée vers les sciences des données !



Faire le lien entre une situation réelle et un modèle Statistique

① avec un modèle paramétrique






# MAPSI, un peu plus concrètement

Faire le lien entre une situation réelle et un modèle Statistique


- 1 avec un modèle paramétrique



# MAPSI, un peu plus concrètement

Faire le lien entre une situation réelle et un modèle Statistique


❶ avec un modèle paramétrique




# MAPSI, un peu plus concrètement

Faire le lien entre une situation réelle et un modèle Statistique

- 1 avec un modèle paramétrique
- 2 avec un modèle agnostique

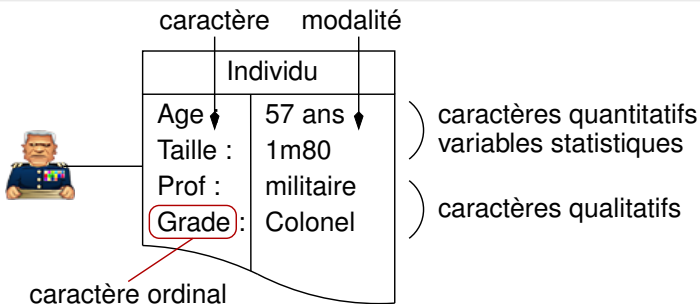


- 1 Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions**
- 3 Description d'une population, d'un échantillon
- 4 Variables multiples, loi jointe, conditionnelle
- 5 Indépendance probabiliste
- 6 Conclusion



## Définitions

- **population (statistique)** : ensemble des objets (ou personnes) sur lesquels porte l'étude
- **individu** : chaque élément de la population



## Définitions

- **Caractères** : critères d'étude de la population
- **Modalités** : les valeurs que peuvent prendre les caractères
- **Caractère quantitatif ou Variable statistique** : ensemble de modalités = des nombres + échelle mathématique
- **Caractère qualitatif ou Variable catégorielle** : caractère non quantitatif
- **Caractère ordinal** : les modalités sont ordonnées



Individu	
Age :	57 ans
Taille :	1m80
Prof :	militaire
Grade :	Colonel

— variable discrète

— variable continue

## *Définitions sur les variables statistiques*

- **Variable discrète** : définie sur un espace discret (par exemple des entiers)
- **Variable continue** : définie sur un continuum (toutes les valeurs numériques d'un intervalle)

## *Quelques définitions de statistiques*


- $X$  : caractère défini sur une population de  $N$  individus
- $\{x_1, \dots, x_I\}$  modalités de  $X$
- $N_i = \text{effectif}$  de  $x_i$   
= nombre d'individus pour lesquels  $X$  a pris la valeur  $x_i$
- **fréquence ou effectif relatif** :  $f_i = \frac{N_i}{N}$
- **distribution** de  $X$  : ensemble des couples  $\{(x_1, f_1), (x_2, f_2), \dots\}$   
Représentation usuelle sous forme de tableau

Statistiques = description d'un échantillon

Probabilités = description d'une population.




# Probabilités : approche événementielle



# Les événements : des ensembles (1/2)

événement = sous-ensemble de  $\Omega$

$\emptyset$  = événement impossible



## Notations ensemblistes :

- événements = sous-ensembles de  $\Omega$
- $\emptyset$  = événement impossible
- $A \cup B$  = événement qui est réalisé si  $A$  ou  $B$  est réalisé
- $C \cap D$  = événement qui est réalisé si  $C$  et  $D$  sont réalisés
- $\overline{C \cup D}$  = complémentaire de  $C \cup D$  dans  $\Omega$   
= événement qui est réalisé ssi  $C \cup D$  ne l'est pas
- $A \cap B = \emptyset$  = 2 événements qui ne peuvent se réaliser simultanément

## *Définition des probabilités (Kolmogorov)*

- $\Omega$  = ensemble fini ou dénombrable  
d'événements élémentaires  $e_k, k \in K \subseteq \mathbb{N}$
- $\mathcal{A} = 2^{|\Omega|}$  = ensemble des événements
- Mesure de probabilité :  $\forall A \in \mathcal{A}, 0 \leq P(A) \leq 1$
- $P(\Omega) = 1$
- $A = \bigcup_{k \in L} A_k$ , avec  $L$  ensemble dénombrable et,  $\forall j, k \in L, j \neq k, A_j \cap A_k = \emptyset$ ,  
$$P(A) = \sum_{k \in L} P(A_k).$$

$\Rightarrow$  Les probabilités des événements élémentaires déterminent entièrement  $P$

conséquence :  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

## Quelques définitions de probabilités

- **Univers**  $\Omega$  : un ensemble dénombrable (fini ou infini)
- **Evènement** : un sous-ensemble de l'univers  $\Omega$
- **Mesure de probabilité** :  
une fonction qui associe à chaque évènement une valeur entre 0 et 1, la probabilité de  $\Omega$  est 1, et la probabilité d'une union dénombrable d'évènements incompatibles (ensembles disjoints) est la somme de leurs probabilités.
- **Espace probabilisé** :  
un couple  $(\Omega, P)$  où  $P$  est une mesure de probabilité sur  $\Omega$ .
- **Variable aléatoire**

## Variable aléatoire

Lorsqu'on est face à une expérience aléatoire, on s'intéresse plus souvent à une *valeur* attribuée au résultat qu'au résultat lui-même.

## Exemples

- Lorsque l'on joue à un jeu de hasard on s'intéresse plus au gain que l'on peut obtenir qu'au résultat du jeu.
  - Nombre de pannes dans un ensemble de systèmes plutôt que l'état exact des systèmes
- Solution : “traduire” l'univers en évènements “compréhensibles”.
- ⇒ variable aléatoire : application de l'univers  $\Omega$  vers un autre ensemble.

## Exemple du lancer de dé

On lance un dé après avoir misé 1 EUR. Si le résultat est un 5 ou un 6 on double la mise, sinon perd la mise. Dans ce cas :

- $\Omega = \{1, 2, 3, 4, 5, 6\}$
- $\text{Card } \Omega = 6$ , et  $\forall e \in \Omega, P(e) = \frac{1}{6}$
- Soit  $X$  la v.a. qui associe à tout résultat du dé un *gain* :  
 $X(1) = X(2) = X(3) = X(4) = -1$  et  $X(5) = X(6) = (2 - 1) = 1$   
 $X$  est à valeur dans l'ensemble noté  $\mathcal{X} = \{-1, 1\} \subset \mathbb{R}$ ,  
 $X : \Omega \rightarrow \mathcal{X}$
- Question :  
**Comment calculer la probabilité de gagner 1 EUR ?**
- Réponse : Définir une probabilité sur  $\mathcal{X}$ , notée  $\mathbb{P}$ , en retournant dans l'espace probabilisé  $(\Omega, \mathcal{P}(\Omega), P)$   
i.e. utiliser  $P(\text{résultat du dé} = 5 \text{ ou } 6)$  pour estimer  $\mathbb{P}(\{1\})$ .

## Définition Variable aléatoire à valeurs discrètes

Soit  $\Omega$  un ensemble dénombrable, et  $P$  une mesure de probabilité sur  $\Omega$ .

Soit  $\Omega'$ , un ensemble discret. Une variable aléatoire est une fonction  $X$  de  $\Omega$  muni de la mesure  $P$  vers  $\Omega'$ .

## Exemples

- Lancer d'un dé :

Soit  $\Omega = \{1, \dots, 6\}$  muni de la probabilité uniforme  $P$ .

$$X : i \mapsto \begin{cases} 1 & \text{si } i \text{ est pair} \\ 0 & \text{sinon} \end{cases}$$

est une variable aléatoire de  $(\Omega, P)$  vers  $\Omega' = \{0, 1\}$ .

- Lancer de deux dés :

Soit  $\Omega = \{1, \dots, 6\}^2$  muni de la probabilité uniforme  $P$ .

$$X : (i, j) \mapsto i + j$$

est une variable aléatoire de  $(\Omega, P)$  vers  $\Omega' = \{2, \dots, 12\}$



## Définitions : Loi de probabilité

Soit  $(\Omega, P)$  un espace probabilisé où  $\Omega$  est dénombrable.

Soit  $\Omega'$  un ensemble discret, et  $X$  une v.a. de  $(\Omega, P)$  vers  $\Omega'$ .

- $P_X$  définit une mesure de probabilité sur  $\Omega'$  :

$$\forall E' \subset \Omega', \quad P_X(E') = P(X^{-1}(E'))$$

avec  $X^{-1}(E') = \{\omega \in \Omega | X(\omega) \in E'\}$

- L'ensemble des valeurs  $P_X(\{\omega'\})$  pour  $\omega' \in \Omega'$  s'appelle la *loi de probabilité* de  $X$ .


## Notations

- L'événement  $X \in ]-\infty, a]$  sera noté par  $X \leq a$
- L'événement  $X \in ]a, b]$  sera noté par  $a < X \leq b$
- L'événement  $X \in \{a\}$  sera noté par  $X = a$
- On a donc  $P_X(B) = P(X^{-1}(B)) = P(X \in B)$

- 1 Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon**
- 4 Variables multiples, loi jointe, conditionnelle
- 5 Indépendance probabiliste
- 6 Conclusion



## DESCRIPTION D'UNE POPULATION

- A partir d'un échantillon
- En simplifiant les données continues
- Simplifiant les différentes dimensions, ...






## DESCRIPTION D'UNE POPULATION

- A partir d'un échantillon
- En simplifiant les données continues
- Simplifiant les différentes dimensions, ...






## DESCRIPTION D'UNE POPULATION

- A partir d'un échantillon
- En simplifiant les données continues
- Simplifiant les différentes dimensions, ...



## DESCRIPTION D'UNE POPULATION




- A partir d'un échantillon
- En simplifiant les données continues
- Simplifiant les différentes dimensions, ...



Moyennes : 0.56   0.59   0.47

## DESCRIPTION D'UNE POPULATION

- A partir d'un échantillon
- En simplifiant les données continues
- Simplifiant les différentes dimensions, ...




Moyennes : 0.56   0.59   0.47  
Ou même une moyenne générale : 0.54


Décrire parfaitement une population = connaître sa loi de probabilité

Exemples selon la nature des variables :

*en continu :*



*en discret :*





Décrire parfaitement une population = connaître sa loi de probabilité

Problème général :

Comment déduire la loi sur la population si on ne connaît qu'un échantillon ?

Réponse dans les cours suivants...


## *Cas général :*

- Une distribution somme à 1
- Une probabilité est toujours  $\geq 0$


## *Cas Continu :*

- Chaque événement élémentaire a une proba = 0  
(eg : proba d'avoir 40 ans)
- Mais proba d'être dans un intervalle  $\geq 0$   
(eg : proba d'avoir entre 40 et 50 ans)

$P(A)$  = surface délimitée par la  
**fonction de densité** dans la zone  
où les événements sont inclus  
dans  $A$



# Probabilités : les détails dans le cas continu



$$P(X \in I) = \int_I p(x) dx$$

avec  $P$  = proba et  $p$  = fonction de densité


$\Rightarrow$  connaître  $p$  = connaître  $P$

intervalles  $] -\infty, x[ \Rightarrow$  fonction de répartition :


$$F(x) = P(X < x) = \int_{-\infty}^x p(y) dy$$

Continu  $\rightarrow$  Discret

Possibilité de discrétisation = regroupement par tranches  
Modélisation approximative, mais manipulation plus facile



Distribution des salaires en France



Distribution des salaires en France  
**discrétisée**

## Caractéristiques

- **Espérance mathématique** ou **moyenne** :  $E(X)$

$X$  discrète :  $E(X) = \sum x_k p_k$

$X$  continue :  $E(X) = \int x p(x) dx$



l'espérance mathématique n'existe pas toujours

- **Mode** :  $Mo$  de  $P$  (pas toujours unique) :

$X$  discrète :  $p(Mo) = \max_k p(x_k)$

$X$  continue :  $p(Mo) = \max_x p(x)$

## Propriétés de l'espérance

- $E(aX + b) = aE(X) + b$
- $\forall X, Y, E(X + Y) = E(X) + E(Y)$

- **variance** :  $V(X)$  ou  $\sigma^2$  :

$X$  discrète :  $\sigma^2 = \sum [x_k - E(X)]^2 p_k$


$X$  continue :  $\sigma^2 = \int [x - E(X)]^2 p(x) dx$

- moyenne des carrés des écarts entre les valeurs prises par  $X$  et son espérance  $E(X)$
- **écart-type** :  $\sigma$  = racine carrée de la variance
- variance et donc écart-type n'existent pas toujours
- **Prop** :  $Y = aX + b$ , où  $a$  et  $b$  sont des nombres réels  
 $V(Y) = a^2 V(X)$
- **Prop** :  $V(X) = E[X^2] - E[X]^2$


# Résumer les informations prépondérantes

## Idées :

- 1 Caractériser rapidement une distribution
  - 2 Donner en quelques chiffres une idée approchée de l'ensemble de la distribution de probabilité.
- Espérance, variance + moments statistiques



Niveau du sol sur la planète



Médiane = 1650, Moyenne = 2000


- Quantiles (médianes, ...)

# Médiane d'une variable statistique continue


## Médiane d'une variable statistique continue

- $X$  : variable statistique continue
- **Médiane** = le nombre  $\delta$  tel que les aires situées de part et d'autre de ce nombre dans l'histogramme représentant  $X$  sont égales

**Médiane**  $M$  :  $P(X \leq M) \geq \frac{1}{2}$  et  $P(X \geq M) \geq \frac{1}{2}$



## World Median Ages



**YOUNGEST:** 1. Niger (15.1) 2. Uganda (15.5) 3. Mali (16) 4. Malawi (16.3) 5. Zambia (16.7)  
**OLDEST:** 1. Germany & Japan (46.1) 2. Italy (44.5) 3. Austria (44.3) 4. Virgin Islands (44.2)



## Quantile d'une variable discrète

- $X$  : variable statistique discrète, modalités  $\{x_1, \dots, x_I\}$
- population de  $N$  individus ( $N_i = \text{effectif de } x_i$ )
- **quantile d'ordre**  $\alpha = \delta$  tel que :

$$\sum_{i \in \{j: x_j < \delta\}} N_i \leq \alpha N \quad \text{et} \quad \sum_{i \in \{j: x_j > \delta\}} N_i \leq (1 - \alpha)N$$

## Quantile d'une variable continue

- $X$  : variable statistique continue
- **quantile d'ordre**  $\alpha =$  le nombre  $\delta$  tel que les aires situées de part et d'autre de ce nombre dans l'histogramme représentant  $X$  sont égales respectivement à  $\alpha \times \text{aire totale}$  et  $(1 - \alpha) \times \text{aire totale}$

- 1 Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon
- 4 Variables multiples, loi jointe, conditionnelle**
- 5 Indépendance probabiliste
- 6 Conclusion

- Chaque individu de la population est décrit sur plusieurs caractères

Exemples :

- Carte à jouer : Couleur (Trefle, Carreau, Coeur, Pique), Valeur (7, ..., Roi)
- Sportifs : Age ( $< 20$ , ...,  $> 50$ ), Sport pratiqué (Natation...)

Loi jointe  $P(A, B)$  : décrire toutes les intersections possibles

*Exemple :*

Sport \ Age	$< 20$	$[20, 30[$	$[30, 40[$	$[40, 50[$	$\geq 50$
Natation	0.02	0.05	0.09	0.08	0.08
Jogging	0.10	0.15	0.10	0.07	0.05
Tennis	0.02	0.03	0.06	0.07	0.03

NB : l'ensemble de l'univers  $\Omega$  somme toujours à 1

## Définition

La marginalisation consiste à projeter une loi jointe sur l'une des variables aléatoires.

Par exemple, extraire  $P(A)$  à partir de  $P(A, B)$ .

$$P(A) = \sum_i P(A, B = b_i)$$

Sport \ Age	< 20	[20, 30[	[30, 40[	[40, 50[	≥ 50	Marginale
Natation	0.02	0.05	0.09	0.08	0.08	0.32
Jogging	0.10	0.15	0.10	0.07	0.05	0.47
Tennis	0.02	0.03	0.06	0.07	0.03	0.21
						1

La marginale extraite ici correspond à  $P(\text{Sport})$ . La nouvelle loi somme toujours à 1.

## Définition

La marginalisation consiste à projeter une loi jointe sur l'une des variables aléatoires.

Par exemple, extraire  $P(A)$  à partir de  $P(A, B)$ .

$$P(A) = \sum_i P(A, B = b_i)$$

Sport \ Age	< 20	[20, 30[	[30, 40[,	[40, 50[	≥ 50
Natation	0.02	0.05	0.09	0.08	0.08
Jogging	0.10	0.15	0.10	0.07	0.05
Tennis	0.02	0.03	0.06	0.07	0.03
Marginale	0.14	0.23	0.25	0.22	0.16

## *Définition*

la probabilité d'un événement  $A$  conditionnellement à un événement  $B$ , que l'on note  $P(A|B)$ , est la probabilité que  $A$  se produise sachant que  $B$  s'est ou va se produire.

Rem :  $P(A|\Omega) = P(A)$  puisqu'on sait que  $\Omega$  sera réalisé

Problème : comment calculer  $P(A|B)$  ?

## Exemple

- Tirer une carte parmi un jeu de 32 cartes
- $\Omega = \{32 \text{ cartes}\}$
- événements :  $A = \text{tirer un roi}$        $B = \text{tirer un cœur}$
- $P(A|B) = ?$

## Interprétation de $P(A|B)$

Dans l'univers réduit  $B$  ( $\Omega' = B$ ), quelle est la probabilité de  $A$  ?

## Exemple

- Tirer une carte parmi un jeu de 32 cartes
- $\Omega = \{32 \text{ cartes}\}$
- événements :  $A = \text{tirer un roi}$        $B = \text{tirer un cœur}$
- $P(A|B) = ?$

## Interprétation de $P(A|B)$

Dans l'univers réduit  $B$  ( $\Omega' = B$ ), quelle est la probabilité de  $A$  ?

- $\Omega' = B = \text{cœur}$  (8 cartes)
- $P(A|B) = \text{un roi parmi les cœur...}$



## Exemple

- Tirer une carte parmi un jeu de 32 cartes
- $\Omega = \{32 \text{ cartes}\}$
- événements :  $A = \text{tirer un roi}$        $B = \text{tirer un cœur}$
- $P(A|B) = ?$

## Interprétation de $P(A|B)$

Dans l'univers réduit  $B$  ( $\Omega' = B$ ), quelle est la probabilité de  $A$  ?

- $\Omega' = B = \text{cœur}$  (8 cartes)
- $P(A|B) = \text{un roi parmi les cœur...}$

$$P(A|B) = \frac{1}{8}$$

Théorème des probabilités totales :

En partant de la loi jointe

$$P(A|B) = \frac{P(A, B)}{P(B)} \text{ ou } P(A, B) = P(A|B)P(B)$$

**Interprétation :** l'observation conjointe de  $A$  et  $B$  ( $P(A, B)$ ) correspond à l'observation de  $B$  ET à l'observation de  $A$  dans l'univers restreint  $B$ .

Théorème des probabilités totales :

En partant de la loi jointe

$$P(A|B) = \frac{P(A, B)}{P(B)} \text{ ou } P(A, B) = P(A|B)P(B)$$

**Interprétation :** l'observation conjointe de  $A$  et  $B$  ( $P(A, B)$ ) correspond à l'observation de  $B$  ET à l'observation de  $A$  dans l'univers restreint  $B$ .

**Exemple :** Roi de coeur = Observer un coeur ET observer un roi dans l'univers des coeurs

## Propriétés

- Réversible :  $P(A, B) = P(A|B)P(B) = P(B|A)P(A)$
- Théorème de Bayes :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- Intégration des probabilités totales :

$$P(A) = \sum_i P(A, B = b_i) = \sum_i P(A|B = b_i)P(B_i)$$

Tableau de probabilité conditionnelle :

- Sport :  $P(S) =$ 

Natation	0.32
Jogging	0.47
Tennis	0.21

- Répartition des ages pour chaque sport :  
 $P(A|S) =$

Sport \ Age	< 20	[20, 30[	[30, 40[,	[40, 50[	$\geq 50$
Natation	0.06	0.16	0.28	0.25	0.25
Jogging	0.21	0.32	0.21	0.15	0.11
Tennis	0.10	0.14	0.29	0.33	0.14

- **Propriété** : chaque ligne somme à 1 (=chaque ligne est un univers à part)
- **Questions** : comment extraire la distribution des ages ?  
Comment obtenir la distribution jointe ?

- 1 Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon
- 4 Variables multiples, loi jointe, conditionnelle
- 5 Indépendance probabiliste**
- 6 Conclusion

## *Définition de l'indépendance*

deux événements  $A$  et  $B$  sont indépendants si :

$$P(A, B) = P(A) \times P(B)$$

Corrolaire : deux événements  $A$  et  $B$  sont indépendants si :

$$P(A|B) = P(A) \text{ (avec } P(B) > 0)$$

l'indépendance n'est pas une propriété du couple  $(A, B)$  mais du couple  $(\{A, A^c\}, \{B, B^c\})$  :

$A$  et  $B$  sont indépendants  $\implies A$  et  $B^c$  indépendants  
 $\implies A^c$  et  $B$  indépendants  
 $\implies A^c$  et  $B^c$  indépendants

## Démonstration :

$A$  et  $B$  sont indépendants  $\implies P(A, B) = P(A) \times P(B)$

$$P(A) = P(A, B) + P(A, B^c)$$

$$\implies P(A, B^c) = P(A) - P(A, B)$$



$$= P(A) - P(A) \times P(B)$$

$$= P(A) \times [1 - P(B)]$$

$$= P(A) \times P(B^c)$$



## Exemple



Qu'est ce qui est dépendant ou indépendant ?

# Indépendance (exemple)

Indépendance ou pas entre X et Y ?

Cas 1 :

	$y_1$	$y_2$
$x_1$	0.04	0.06
$x_2$	0.36	0.54

Cas 3 :

	$y_1$	$y_2$	$y_3$
$x_1$	0.07	0.24	0.16
$x_2$	0.07	0.30	0.16

Cas 2 :



	$y_1$	$y_2$
$x_1$	0.1	0.2
$x_2$	0.3	0.4

Cas 4 :




	$y_1$	$y_2$	$y_3$
$x_1$	0.01	0.02	0.07
$x_2$	0.09	0.18	0.63

# Indépendance (exemple graphique)

Représentation d'une loi jointe  $P(X_1, X_2)$





Représentation d'une loi jointe  $P(X_1, X_2)$



# Indépendance (exemple graphique)

Représentation d'une loi jointe  $P(X_1, X_2)$



- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul) ?



# Indépendance : pourquoi c'est important

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul) ?
  - Indépendance ! Dés identiques = 6 valeurs
  - Dés différents =  $3 \times 6 = 18$  valeurs
  - Dés non indépendants ( ? )  $6 \times 6 \times 6 = 216$  valeurs

# Indépendance : pourquoi c'est important

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul) ?
  - Indépendance ! Dés identiques = 6 valeurs
  - Dés différents =  $3 \times 6 = 18$  valeurs
  - Dés non indépendants ( ? )  $6 \times 6 \times 6 = 216$  valeurs
- Combien de variables pour modéliser les probabilités d'apparition de groupes de 3 mots (tri-grammes) ? -Vocabulaire réduit à 10k mots-

# Indépendance : pourquoi c'est important

- Combien de variable pour modéliser la probabilité de voir son toit s'envoler ?  $12 \times 6 \times 10 = 720$ 
  - Mois de l'année (12)
  - Catégorie des ouragans (6)
  - Type de construction (10)
- Combien de variable pour modéliser les probabilités de tirage de 3 dés (cumul) ?
  - Indépendance ! Dés identiques = 6 valeurs
  - Dés différents =  $3 \times 6 = 18$  valeurs
  - Dés non indépendants (?)  $6 \times 6 \times 6 = 216$  valeurs
- Combien de variables pour modéliser les probabilités d'apparition de groupes de 3 mots (tri-grammes) ? -Vocabulaire réduit à 10k mots-
  - $10k^3 = 10^{12}$  valeurs (=4000 Go)

## Propriétés de la variance

- $\forall X, Y, V(X + Y) = V(X) + V(Y) + 2cov(X, Y)$  où :
  - $cov(X, Y) = \text{covariance}$  de  $X$  et  $Y$

$$COV(X, Y) = E[(X - E[X])(Y - E[Y])]$$

- si  $X$  et  $Y$  discrètes

$$COV(X, Y) = \sum_i \sum_j (x_i - E[X])(y_j - E[Y])P(X = x_i, \cap Y = y_j)$$

- si  $X$  et  $Y$  continues, de densité  $p(x, y)$ ,

$$cov(X, Y) = \iint [x - E(X)][y - E(Y)]p(x, y)dx dy$$

Estimateur sur un échantillon :  $\{(x_1, y_1), \dots, (x_k, y_k), \dots, (x_N, y_N)\}$

$$cov(X, Y) = \frac{1}{N} \sum_k (x_k - \bar{x})(y_k - \bar{y})$$

## Définition : Coefficient de corrélation linéaire

Soit  $X, Y$  deux variables. Le coefficient de corrélation linéaire entre  $X$  et  $Y$  est :

$$r = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y},$$

où  $\sigma_X$  et  $\sigma_Y$  sont les écart-types des variables  $X$  et  $Y$ .

- 1 Fonctionnement de l'UE MAPSI
- 2 Variables aléatoires & probabilités : vocabulaire, définitions
- 3 Description d'une population, d'un échantillon
- 4 Variables multiples, loi jointe, conditionnelle
- 5 Indépendance probabiliste
- 6 Conclusion

## Les 4 règles qui vont vous sauver la vie.

- Probabilité :

$$\forall x \in \mathcal{X}, \quad 0 \leq P(x) \leq 1 \text{ et } \sum_{x \in \mathcal{X}} p(x) = 1$$

- Marginalisation

$$P(X_1 = x_1) = \sum_{x_2, \dots, x_n} P(X_1 = x_1, X_2 = x_2, \dots)$$

- Conditionnement :

$$P(X_1, X_2) = P(X_1|X_2)P(X_2) \text{ (et vice versa)}$$

- Indépendance :

Si  $X_1$  et  $X_2$  sont indépendantes :  $P(X_1, X_2) = P(X_1)P(X_2)$