

MAPSI — cours 3 :  
Maximum de vraisemblance  
Maximum a posteriori

Pierre-Henri Wuillemin & Christophe Gonzales

LIP6 / ISIR – Sorbonne Université, France

- 1 Vraisemblance et prise de décision
- 2 Estimation par maximum de vraisemblance (ML)
- 3 Estimation par maximum a posteriori (MAP)

## 2 Vraisemblance et prise de décision

# Vraisemblance d'un échantillon : loi discrète connue

- Échantillon  $\mathbf{x} = (x_1, \dots, x_n)$  de taille  $n$
- Échantillon  $\implies$  les  $x_i$  = réalisations de variables aléatoires  $X_i$
- Échantillon i.i.d.  $\implies$  les  $X_i$  sont **mutuellement** indépendants

$$\implies P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$



l'hypothèse i.i.d est essentielle !

## *Vraisemblance d'un échantillon dans le cas discret*

- $L(\mathbf{x})$  = Vraisemblance de l'échantillon
- $L(\mathbf{x})$  = proba d'obtenir **cet** échantillon sachant la loi  $P$

$$L(\mathbf{x}) = P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i)$$

# Vraisemblance d'un échantillon : loi discrète connue

- pièce de monnaie :  $P(\text{Pile}) = 0,75$  et  $P(\text{Face}) = 0,25$
- jet de la pièce  $\Rightarrow$  expérience de Bernoulli  
 $\Rightarrow$  hypothèse i.i.d. vérifiée



● échantillon 1 : 

P	P	F	F	P	P	F	P	P	P
---	---	---	---	---	---	---	---	---	---

$$\begin{aligned}\Rightarrow L(\mathbf{x}) &= \prod_{i=1}^7 P(\text{Pile}) \times \prod_{i=1}^3 P(\text{Face}) \\ &= 0,75^7 \times 0,25^3 \approx 0,002086\end{aligned}$$

● échantillon 2 : 




F	F	P	P	F	F	P	F	F	F
---	---	---	---	---	---	---	---	---	---

$$\begin{aligned}\Rightarrow L(\mathbf{x}) &= \prod_{i=1}^3 P(\text{Pile}) \times \prod_{i=1}^7 P(\text{Face}) \\ &= 0,75^3 \times 0,25^7 \approx 0,000026\end{aligned}$$

# Prévention des risques d'inondation (1/4)

- Plan de prévention des risques d'inondations (PPR-I) :

photos satellite SPOT5  $\implies$  zones susceptibles d'être inondées



- 3 catégories de parcelles :

- 1 inondables ( $PI$ )
- 2 partiellement inondables ( $PPI$ )
- 3 non inondables ( $NI$ )

# Prévention des risques d'inondation (2/4)

- images en teintes de gris
- proba d'obtenir un niveau de gris  $n$  dépend du type de zone :

$$P(n|PI) = \mathcal{N}(\mu_1, \sigma_1^2)$$

$$\mu_1 = 100 \quad \sigma_1 = 20$$

$$P(n|PPI) = \mathcal{N}(\mu_2, \sigma_2^2)$$

$$\mu_2 = 85 \quad \sigma_2 = 5$$

- nouvelle image envoyée par SPOT5 :



- zone  $Z$  : niveau de gris =  $n = 80$

Problème : zone  $Z = PI$  ou  $PPI$ ?

Problème : zone  $Z = PI$  ou  $PPI$  ?

• 2 hypothèses :

①  $\theta_1 = \text{« } Z \text{ est de type } PI \text{ »}$

②  $\theta_2 = \text{« } Z \text{ est de type } PPI \text{ »}$

• **Idée** : calcul du max de vraisemblance d'obtenir la zone  $Z$   
sous  $\theta_1$  ou sous  $\theta_2$

•  $L(\mathbf{x}, \theta_1) = p(80|PI)$ , avec  $p$  fct de densité de  $P(n|PI) = \mathcal{N}(\mu_1, \sigma_1^2)$

**Rappel** : la fonction de densité de  $\mathcal{N}(\mu, \sigma^2)$  est :

$$p(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \exp \left\{ -\frac{1}{2} \left( \frac{x - \mu}{\sigma} \right)^2 \right\}$$



Problème : zone  $Z = PI$  ou  $PPI$ ?

- $P(n|PI) = \mathcal{N}(\mu_1, \sigma_1^2) = \mathcal{N}(100, 20^2)$

- $L(\mathbf{x}, \theta_1) = p(80|PI)$ 
$$= \frac{1}{\sqrt{2\pi} \times 20} \exp \left\{ -\frac{1}{2} \left( \frac{80-100}{20} \right)^2 \right\}$$
$$= \frac{1}{20\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \right\}$$
$$\approx 0,0121$$

- $P(n|PPI) = \mathcal{N}(\mu_2, \sigma_2^2) = \mathcal{N}(85, 5^2)$

- $L(\mathbf{x}, \theta_2) = p(80|PPI) = \frac{1}{\sqrt{2\pi} \times 5} \exp \left\{ -\frac{1}{2} \left( \frac{80-85}{5} \right)^2 \right\} \approx 0,0484$

Max de vraisemblance  $\implies PPI$  plus probable

## 2 ML : Estimation par maximum de vraisemblance

# Apprentissage par vraisemblance : le cas discret

- Paramètre à estimer :  $\Theta$

Exemple 1 :



$X \in \{\text{pile}, \text{face}\}$

$$P(X) = \begin{array}{cc} \text{pile} & \text{face} \\ \hline \theta_1 & \theta_2 \end{array} \implies \Theta = \{\theta_1, \theta_2\}$$

Exemple 2 : recommandations :  $r_A \in \{1, 2, 3\}, r_B \in \{a, b\}$

$$P(r_A, r_B) = \begin{array}{cc} & a & b \\ \begin{array}{c} 1 \\ 2 \\ 3 \end{array} & \begin{array}{|c|c|} \hline \theta_1 & \theta_2 \\ \hline \theta_3 & \theta_4 \\ \hline \theta_5 & \theta_6 \\ \hline \end{array} \end{array} \implies \Theta = \{\theta_1, \dots, \theta_6\}$$

# Apprentissage par vraisemblance : le cas discret

- Paramètre à estimer :  $\Theta$
- Échantillon  $\mathbf{x} = (x_1, \dots, x_n)$  de taille  $n$
- Échantillon  $\implies$  les  $x_i$  = réalisations de variables aléatoires  $X_i$
- Échantillon i.i.d.  $\implies$  les  $X_i$  sont **mutuellement** indépendants

$$\implies P(X_1 = x_1, \dots, X_n = x_n | \Theta = \theta) = \prod_{i=1}^n P(X_i = x_i | \Theta = \theta)$$

## *Vraisemblance d'un échantillon dans le cas discret*

- $L(\mathbf{x}, \theta)$  = Vraisemblance de l'échantillon
- $L(\mathbf{x}, \theta)$  = proba d'obtenir **cet** échantillon sachant que  $\Theta = \theta$

$$L(\mathbf{x}, \theta) = P(x_1, \dots, x_n | \Theta = \theta) = \prod_{i=1}^n P(x_i | \Theta = \theta)$$

# Vraisemblance d'un échantillon : le cas continu

- Paramètre à estimer :  $\Theta$
- Échantillon  $\mathbf{x} = (x_1, \dots, x_n)$  de taille  $n$
- Échantillon i.i.d.  $\implies$  les  $X_i$  sont mutuellement indépendants
- $p$  : fonction de densité

$$\implies p(X_1 = x_1, \dots, X_n = x_n | \Theta = \theta) = \prod_{i=1}^n p(X_i = x_i | \Theta = \theta)$$

## *Vraisemblance d'un échantillon dans le cas continu*

- $L(\mathbf{x}, \theta)$  = Vraisemblance de l'échantillon
- $L(\mathbf{x}, \theta) = p(x_1, \dots, x_n | \Theta = \theta) = \prod_{i=1}^n p(x_i | \Theta = \theta)$

# Apprentissage de $\Theta$ par vraisemblance

- pièce de monnaie :  $P(\text{Pile}) = \theta_1 = ???$  et  $P(\text{Face}) = \theta_2 = ???$
- paramètre  $\Theta$  = proba de Pile =  $\theta_1 = ???$

● échantillon : 


P	P	F	F	P	P	F	P	P	P
---	---	---	---	---	---	---	---	---	---

$$\Rightarrow L(\mathbf{x}, \Theta) = \prod_{i=1}^7 P(\text{Pile}|\Theta) \times \prod_{i=1}^3 P(\text{Face}|\Theta)$$

- 
- $\theta_1 = 0,75 \Rightarrow L(\mathbf{x}, \theta_1) = 0,75^7 \times 0,25^3 \approx 0,002086$
  - $\theta_2 = 0,5 \Rightarrow L(\mathbf{x}, \theta_2) = 0,5^7 \times 0,5^3 \approx 0,000976$
  - $\theta_3 = 0,25 \Rightarrow L(\mathbf{x}, \theta_3) = 0,25^7 \times 0,75^3 \approx 0,000026$

$\Rightarrow \theta_1$  plus vraisemblable que  $\theta_2$  ou  $\theta_3$

# Apprentissage de $\Theta$ par vraisemblance



solution optimale :  $\theta = 0,7$

## *Estimateur du maximum de vraisemblance*

- $X$  : variable aléatoire sur la population
- $X$  suit une loi de proba de paramètre  $\Theta$  inconnu
- $\Theta$  : ensemble des valeurs possibles pour  $\Theta$
- $\mathbf{x}$  : échantillon i.i.d.
- $T = f(X) = \text{estimateur du maximum de vraisemblance}$   
défini par  $\mathbf{x} \mapsto t = f(\mathbf{x}) = \underset{\theta \in \Theta}{\text{Argmax}} L(\mathbf{x}, \theta)$

$\implies t = \text{valeur } \theta \text{ de } \Theta \text{ pour laquelle la proba d'observer } \mathbf{x} \text{ était la plus grande}$



# Calcul du maximum de vraisemblance

Problème : comment calculer le maximum de vraisemblance ?

- $\underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} P(x_1, \dots, x_n | \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \prod_{i=1}^n P(x_i | \theta)$

- Certaines conditions de concavité et de dérivabilité

$$\implies \underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) \text{ obtenu lorsque } \frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0$$

- $\underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \ln L(\mathbf{x}, \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \sum_{i=1}^n \ln P(x_i | \theta)$

$$\underset{\theta \in \Theta}{\operatorname{Argmax}} \ln L(\mathbf{x}, \theta) = \log \text{ vraisemblance}$$

$$\implies \underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) \text{ obtenu lorsque } \sum_{i=1}^n \frac{\partial \ln P(x_i | \theta)}{\partial \theta} = 0$$

# Max de vraisemblance et loi binomiale

- pièce de monnaie
- $X \in \{0, 1\}$ ,  $0 \iff \text{Face}$ ,  $1 \iff \text{Pile}$
- $X \sim \mathcal{B}(1, p) \implies P(X = x|p) = p^x(1 - p)^{1-x}$
- $n$  lancers de la pièce  $\implies$  observations  $\mathbf{x} = \{x_1, \dots, x_n\}$
- $P(\mathbf{x}|p) = \prod_{i=1}^n P(x_i|p) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}$

---

**Problème :** à partir de  $\mathbf{x}$ , peut-on raisonnablement déduire  $p$ ?

---

- maximum de vraisemblance :

$$\ln P(\mathbf{x}|p) = \sum_{i=1}^n [x_i \ln p + (1 - x_i) \ln(1 - p)]$$

$$\frac{\partial \ln P(\mathbf{x}|p)}{\partial p} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{n - \sum_{i=1}^n x_i}{1 - p} = 0 \implies p_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

# Max de vraisemblance et loi normale (1/2)

- $X \sim \mathcal{N}(\mu, \sigma^2)$ ; on suppose  $\sigma = 1$
- paramètre  $\Theta =$  espérance  $\mu$
- loi normale  $\implies$  vraisemblance :

$$L(\mathbf{x}, \theta) = \prod_{i=1}^n p(x_i | \theta) = \prod_{i=1}^n \left[ \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} (x_i - \theta)^2 \right\} \right]$$

- $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0 \iff \frac{\partial \ln L(\mathbf{x}, \theta)}{\partial \theta} = 0$

- $\ln L(\mathbf{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2$

- $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0 \iff \sum_{i=1}^n (x_i - \theta) = 0 \iff \theta = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$

Estimateur du maximum de vraisemblance :  $\bar{X}$

# Max de vraisemblance et loi normale (2/2)

- $X \sim \mathcal{N}(\mu, \sigma^2)$
- paramètre  $\Theta = (\mu, \sigma^2)$
- Log vraisemblance :

$$\ln L(\mathbf{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

- Maximum de vraisemblance  $\Rightarrow \frac{\partial L(\mathbf{x}, \theta)}{\partial \mu} = 0$  et  $\frac{\partial L(\mathbf{x}, \theta)}{\partial \sigma^2} = 0$


$$\bullet \begin{cases} \frac{\partial L(\mathbf{x}, \theta)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 & \Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \frac{\partial L(\mathbf{x}, \theta)}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 & \Rightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s_n^2 \end{cases}$$

Estimateurs du maximum de vraisemblance :  $\bar{X}$  et  $S_n^2$



estimateur de la variance biaisé : variance non corrigée

# Problème d'ajustement (1/6)



Observations

$(x_1, t_1)$   
 $\vdots$   
 $(x_{10}, t_{10})$


$\Rightarrow$  courbe  $\sin(2\pi x)$   $\Rightarrow$  estimation de  $t_{11}$

$\Rightarrow$  reconnaissance de la courbe verte

# Problème d'ajustement (2/6)


*Idée :* estimer la courbe verte par un polynôme :

$$y(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^M w_j x^j$$



# Problème d'ajustement (3/6)

*Idée :* les ordonnées des points bleus sont distribuées selon une loi normale autour de  $y(x, \mathbf{w})$  :



$$\Rightarrow P(t|x, \mathbf{w}, \sigma^2) = \mathcal{N}(t|y(x, \mathbf{w}), \sigma^2)$$

*Problème :* comment trouver  $\mathbf{w}$  et  $\sigma^2$  ?

$\Rightarrow$  par maximum de vraisemblance

$$P(t|x, \mathbf{w}, \sigma^2) = \mathcal{N}(t|y(x, \mathbf{w}), \sigma^2)$$

- observations  $\{(x_i, t_i), i = 1, \dots, n\}$
- $\mathbf{t} = \{t_1, \dots, t_n\}$ ;  $\mathbf{x} = \{x_1, \dots, x_n\}$
- observations  $\implies$  échantillon i.i.d

$$\begin{aligned}\implies P(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) &= \prod_{i=1}^n P(t_i|x_i, \mathbf{w}, \sigma^2) \\ &= \prod_{i=1}^n \mathcal{N}(t_i|y(x_i, \mathbf{w}), \sigma^2)\end{aligned}$$

- Max de vraisemblance  $\implies$  calculer la log-vraisemblance :


$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$



# Problème d'ajustement (5/6)

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

- Maximum de log-vraisemblance  $\Rightarrow$  trouver  $\mathbf{w}_{ML}$  et  $\sigma_{ML}^2$  qui maximisent  $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)$
- maximiser par rapport à  $\mathbf{w}_{ML} \iff$  minimiser  $\sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2$



$\Rightarrow$  Moindres carrés

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

- maximiser  $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)$  par rapport à  $\sigma^2 \Rightarrow \frac{\partial \ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)}{\partial \sigma^2} = 0$

- $\frac{\partial \ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 - \frac{n}{2\sigma^4} \sigma^2 = 0$

$$\Rightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2$$

$$\sigma_{ML}^2 = \frac{1}{n} \sum_{i=1}^n [y(x_i, \mathbf{w}_{ML}) - t_i]^2$$

## 2 MAP : Estimation par maximum a posteriori

$$p_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

- 3 lancers  $\implies$  observations : {Pile,Pile,Pile}



- Maximum de vraisemblance  $\implies p_{ML} = 1$

$\implies$  on considère que tout lancer de la pièce devrait tomber sur Pile

$\implies$  résultat à l'encontre du bon sens

$\implies$  autre estimateur : maximum a posteriori

# Le modèle bayésien (1/4)

Maximum a posteriori  $\implies$  modèle bayésien

## *Modèle bayésien*

événements : parties de  $\mathcal{X} \times \Theta$ , où :

- $\mathcal{X}$  = l'espace des observations (échantillons)  $\mathbf{x}$  de taille  $n$
- $\Theta$  = espace des paramètres  $\theta$
- famille des événements dotée d'une loi de proba  $\Pi$

- *cas discret* :  $\Pi$  déterminée par les probas des événements élémentaires  $\pi(\mathbf{x}, \theta)$
- *cas continu* :  $\Pi$  déterminée par la densité jointe  $\pi(\mathbf{x}, \theta)$



Max de vraisemblance :  $\pi(\mathbf{x}|\theta)$  au lieu de  $\pi(\mathbf{x}, \theta) = \pi(\mathbf{x}|\theta)\pi(\theta)$

# Le modèle bayésien (2/4)

## Le cas discret :

- $\pi(\mathbf{x}, \theta) = \Pi(X = \mathbf{x}, \Theta = \theta)$ , où  $X, \Theta$  variables aléatoires
- $\pi(\mathbf{x}) = \Pi(X = \mathbf{x}) = \sum_{\theta \in \Theta} \Pi(X = \mathbf{x}, \Theta = \theta) = \sum_{\theta \in \Theta} \pi(\mathbf{x}, \theta)$
- $\pi(\theta) = \Pi(\Theta = \theta) = \sum_{\mathbf{x} \in \mathcal{X}} \Pi(X = \mathbf{x}, \Theta = \theta) = \sum_{\mathbf{x} \in \mathcal{X}} \pi(\mathbf{x}, \theta)$
- $\pi(\mathbf{x}|\theta) = \Pi(X = \mathbf{x}|\Theta = \theta) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\theta)}$
- $\pi(\theta|\mathbf{x}) = \Pi(\Theta = \theta|X = \mathbf{x}) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\mathbf{x})}$

## *Probabilités a priori et a posteriori*

- $\pi(\theta)$  = probabilité a priori de  $\theta$
- $\pi(\theta|\mathbf{x})$  = probabilité a posteriori de  $\theta$

## Le cas continu :

- $\pi(\mathbf{x}) = \Pi(X = \mathbf{x}) = \int_{\theta \in \Theta} \Pi(X = \mathbf{x}, \Theta = \theta) d\theta = \int_{\theta \in \Theta} \pi(\mathbf{x}, \theta) d\theta$
- $\pi(\theta) = \Pi(\Theta = \theta) = \int_{\mathbf{x} \in \mathcal{X}} \Pi(X = \mathbf{x}, \Theta = \theta) d\mathbf{x} = \int_{\mathbf{x} \in \mathcal{X}} \pi(\mathbf{x}, \theta) d\mathbf{x}$
- $\pi(\mathbf{x}|\theta) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\theta)}$
- $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\mathbf{x})}$

## Probabilités a priori et a posteriori

- $\pi(\theta)$  = probabilité a priori de  $\Theta$   
= idée que l'on se fait de  $\Theta$  avant observation
- $\pi(\theta|\mathbf{x})$  = probabilité a posteriori de  $\Theta$   
= idée que l'on se fait de  $\Theta$  après observation

- Formule de Bayes :  $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\pi(\mathbf{x})}$

- $$\begin{cases} \text{cas discret : } \pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}, \theta)} = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)} \\ \text{cas continu : } \pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}, \theta) d\theta} = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta) d\theta} \end{cases}$$

- **Rappel** :  $\pi(\mathbf{x}|\theta) = \text{vraisemblance de l'échantillon} = L(\mathbf{x}, \theta)$



## Maximum a posteriori (MAP)

$T$  estimateur du maximum a posteriori de  $\Theta$  :

défini par  $\mathbf{x} \mapsto t = \underset{\theta \in \Theta}{\text{Argmax}} \pi(\theta|\mathbf{x})$

- échantillon i.i.d de  $n$  observations

- $X = (X_1, \dots, X_n) \implies \mathbf{x} = (x_1, \dots, x_n)$  observation de  $X$

- $$\begin{cases} \text{cas discret} : \pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \\ \text{cas continu} : \pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\int_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)d\theta} \end{cases}$$

- échantillon i.i.d  $\implies \pi(\mathbf{x}|\theta) = L(\mathbf{x}, \theta) = \begin{cases} \prod_{i=1}^n P(x_i|\theta) & (\text{discret}) \\ \prod_{i=1}^n p(x_i|\theta) & (\text{continu}) \end{cases}$

# MAP : retour sur la pièce de monnaie (1/6)

- pièce de monnaie  $\implies X \in \{0, 1\}$

$0 \iff$  Face



$1 \iff$  Pile



- $X \sim \mathcal{B}(1, \theta) \implies P(X = x|\theta) = \theta^x(1 - \theta)^{1-x}$
- échantillon  $\mathbf{x}$  de 3 lancers  $\implies \{\text{Pile}, \text{Pile}, \text{Pile}\}$
- Max de vraisemblance  $\implies \theta_{ML} = 1$   
 $\implies$  tous les lancers devraient tomber sur Pile



- 
- Modèle bayésien :  $\Theta = \{\theta_1 = 1, \theta_2 = 2/3, \theta_3 = 1/2, \theta_4 = 1/3\}$
  - Info a priori :  $\pi(\theta_1) = \frac{1}{32}, \pi(\theta_2) = \frac{1}{4}, \pi(\theta_3) = \frac{1}{2}, \pi(\theta_4) = \frac{7}{32}$

*Problème* : quelle est la valeur du maximum a posteriori ?

# MAP : retour sur la pièce de monnaie (2/6)

- Modèle bayésien :  $\Theta = \{\theta_1 = 1, \theta_2 = 2/3, \theta_3 = 1/2, \theta_4 = 1/3\}$

- $L(\mathbf{x}, \theta_1) = \pi(\mathbf{x}|\theta_1) = \prod_{i=1}^3 P(x_i|\theta_1) = 1^3 \times 0^0 = 1$

- $L(\mathbf{x}, \theta_2) = \pi(\mathbf{x}|\theta_2) = \prod_{i=1}^3 P(x_i|\theta_2) = \frac{2^3}{3} \times \left(1 - \frac{2}{3}\right)^0 = \frac{2^3}{3} \approx 0,296$

- $L(\mathbf{x}, \theta_3) = \pi(\mathbf{x}|\theta_3) = \prod_{i=1}^3 P(x_i|\theta_3) = \frac{1^3}{2} \times \left(1 - \frac{1}{2}\right)^0 = \frac{1^3}{2} = 0,5$

- $L(\mathbf{x}, \theta_4) = \pi(\mathbf{x}|\theta_4) = \prod_{i=1}^3 P(x_i|\theta_4) = \frac{1^3}{3} \times \left(1 - \frac{1}{3}\right)^0 = \frac{1^3}{3} \approx 0,333$

# MAP : retour sur la pièce de monnaie (3/6)

- Info a priori :  $\pi(\theta_1) = \frac{1}{32}$ ,  $\pi(\theta_2) = \frac{1}{4}$ ,  $\pi(\theta_3) = \frac{1}{2}$ ,  $\pi(\theta_4) = \frac{7}{32}$

- $\pi(\theta_1|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_1)\pi(\theta_1)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto 1 \times \frac{1}{32} = 0,03125$

- $\pi(\theta_2|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_2)\pi(\theta_2)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \frac{2^3}{3} \times \frac{1}{4} \approx 0,074$

- $\pi(\theta_3|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_3)\pi(\theta_3)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \frac{1^3}{2} \times \frac{1}{2} = 0,0625$

- $\pi(\theta_4|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_4)\pi(\theta_4)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \frac{1^3}{3} \times \frac{7}{32} \approx 0,008$


Max a posteriori :  $\Theta = \theta_2 \implies X \sim \mathcal{B}(1, \theta_2) = \mathcal{B}(1, 2/3)$



probabilité que la pièce tombe sur Face  $\neq 0$


# MAP : retour sur la pièce de monnaie (4/6)

- Modèle bayésien :  $\Theta \in [0, 1]$
- Info a priori :  $\Theta \sim$  loi normale tronquée ( $\mu = 1/2, \sigma = 1/4$ ) :
- densité :  $\pi(\theta) = \begin{cases} \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) & \text{si } \theta \in [0, 1] \\ 0 & \text{sinon} \end{cases}$



# MAP : retour sur la pièce de monnaie (5/6)

$$\pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\int_{\theta' \in \Theta} L(\mathbf{x}, \theta')\pi(\theta')} \propto L(\mathbf{x}, \theta)\pi(\theta) = \theta^3 \times \pi(\theta)$$
$$\propto \begin{cases} \theta^3 \times \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) & \text{si } \theta \in [0, 1] \\ 0 & \text{sinon} \end{cases}$$



solution optimale :  $\theta = 0,75$

$$\pi(\theta|\mathbf{x}) \propto \theta^3 \times \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) \text{ pour } \theta \in [0, 1]$$

$$\implies \log \pi(\theta|\mathbf{x}) = 3 \log \theta - \frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2 + \text{constante}$$

$$\implies \frac{\partial \log \pi(\theta|\mathbf{x})}{\partial \theta} = \frac{3}{\theta} - \frac{\theta-\mu}{\sigma^2}$$

$$\implies \frac{\partial \log \pi(\theta|\mathbf{x})}{\partial \theta} = 0 \Leftrightarrow \theta^2 - \mu\theta - 3\sigma^2 = 0$$

$$\implies \theta = 0,75$$

calcul de la distribution a posteriori :  $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)d\theta}$

$\Rightarrow$  si  $\pi(\mathbf{x}|\theta)\pi(\theta)$  complexe analytiquement alors calcul de l'intégrale compliqué

## *Lois conjuguées*

- $\pi(\theta)$  : loi a priori
- $\pi(\mathbf{x}|\theta)$  : fonction de vraisemblance
- $\pi(\theta|\mathbf{x})$  : distribution a posteriori
- $\pi(\theta)$  et  $\pi(\mathbf{x}|\theta)$  sont conjuguées si  $\pi(\theta|\mathbf{x})$  appartient à la même famille de lois que  $\pi(\theta)$



# Lois conjuguées : exemple de la pièce de monnaie

- pièce de monnaie  $\Rightarrow X \in \{0, 1\} : 0 \iff$



$1 \iff$



- $X \sim \mathcal{B}(1, \theta) \Rightarrow$  vraisemblance d'un échantillon :

$$\pi(\mathbf{x}|\theta) = \theta^x (1 - \theta)^{n-x}, \text{ avec } x = \#(x_i = 1)$$

$\Rightarrow$  loi binomiale

## *Distribution de probabilité Beta*

$$\text{Loi Beta : } \text{Beta}(\theta, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1}$$

$$\text{avec } \Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$$





$$\text{Espérance} = \frac{a}{a+b} \quad \text{Variance} = \frac{ab}{(a+b)^2(a+b+1)}$$

$\Rightarrow$  loi Beta et loi binomiales conjuguées

# Lois conjuguées : loi binomiale et loi Beta

- loi a priori :  $\pi(\theta) = \text{Beta}(\theta, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1}$
- fonction de vraisemblance :  $\pi(\mathbf{x}|\theta) = \theta^x (1-\theta)^{n-x}$ , avec  $x = \sum (x_i = 1)$
- loi a posteriori :  $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)} \propto \pi(\mathbf{x}|\theta)\pi(\theta)$
- loi a posteriori :  $\pi(\theta|\mathbf{x}) \propto \theta^{x+a-1} (1-\theta)^{b+n-x-1}$

$$\implies \pi(\theta|\mathbf{x}) \sim \text{Beta}(\theta, x+a, b+n-x)$$



# Comparaison MAP – maximum de vraisemblance

- pièce de monnaie  $\Rightarrow X \in \{0, 1\} : 0 \iff$



$1 \iff$



- Max de vraisemblance :

$$\pi(\mathbf{x}|\theta) = \theta^x(1 - \theta)^{n-x} \Rightarrow \text{Beta}(\theta, x + 1, n - x + 1)$$

- Max a posteriori :

$$\pi(\theta|\mathbf{x}) \propto \theta^{x+a-1}(1 - \theta)^{b+n-x-1} \Rightarrow \text{Beta}(\theta, x + a, n - x + b)$$

$\Rightarrow$  Max de vraisemblance  $\iff$  Max a posteriori avec  $a = 1$  et  $b = 1$

Or  $\text{Beta}(\theta, 1, 1) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} = \text{constante}$

Max de vraisemblance  $\iff$  Max a posteriori avec a priori uniforme



$n \rightarrow +\infty \Rightarrow \text{max de vraisemblance} \approx \text{max a posteriori}$

$\Rightarrow$  l'a priori devient négligeable

# Loi normale et loi conjuguée

- fonction de vraisemblance = loi normale,  $\sigma^2$  connue  
 $\implies$  loi a priori conjuguée : loi  $\Gamma$

## La loi $\Gamma$

- $X \sim \Gamma(x, k, \theta)$
- fonction de densité de la loi  $\Gamma$  :


$$f(x, k, \theta) = x^{k-1} \frac{e^{-x/\theta}}{\theta^k \Gamma(k)} \quad \forall x, k, \theta > 0$$

- $\Gamma(k) = \int_0^{+\infty} t^{k-1} e^{-t} dt$
- $E(X) = k\theta, \quad V(X) = k\theta^2$



Lorsque  $k$  entier :  $\Gamma(x, k, \theta)$  = loi de  $k$  variables indépendantes suivant une loi exponentielle d'espérance  $\theta$




- Familles de lois conjuguées :  
[http://en.wikipedia.org/wiki/Conjugate\\_prior](http://en.wikipedia.org/wiki/Conjugate_prior)



# Prévention des risques d'inondation (1/3)

- Plan de prévention des risques d'inondations (PPR-I) :

photos satellite SPOT5  $\Rightarrow$  zones susceptibles d'être inondées



- 3 catégories de parcelles :

- 1 inondables ( $PI$ )
- 2 partiellement inondables ( $PPI$ )
- 3 non inondables ( $NI$ )

# Prévention des risques d'inondation (2/3)

- images en teintes de gris
- proba d'obtenir un niveau de gris  $n$  dépend du type de zone :

$$P(n|PI) = \mathcal{N}(100, 20^2) \quad P(n|PPI) = \mathcal{N}(85, 5^2)$$

- nouvelle image envoyée par SPOT5 :



- zone  $Z$  : niveau de gris =  $n = 80$
- **Connaissance a priori** : 60% de  $PI$ , 10% de  $PPI$ , 30% de  $NI$

Problème : zone  $Z = PI$  ou  $PPI$ ?



Problème : zone  $Z = PI$  ou  $PPI$ ?

- 2 hypothèses :

- 1  $\theta_1 = \text{« } Z \text{ est de type } PI \text{ »}$
- 2  $\theta_2 = \text{« } Z \text{ est de type } PPI \text{ »}$

- **Idée** : calcul du MAP d'obtenir la zone  $Z$  sous  $\theta_1$  ou sous  $\theta_2$

- $\pi(\theta_1|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_1)\pi(\theta_1)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$        $\pi(\theta_2|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_2)\pi(\theta_2)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$

- Rappel cours 4 :  $L(\mathbf{x}, \theta_1) \approx 0,0121$      $L(\mathbf{x}, \theta_2) \approx 0,0484$



- a priori :  $\pi(\theta_1) = 0,6$      $\pi(\theta_2) = 0,1$

- $\pi(\theta_1|\mathbf{x}) = \frac{0,0121 \times 0,6}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$        $\pi(\theta_2|\mathbf{x}) = \frac{0,0484 \times 0,1}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$

MAP  $\Rightarrow$  parcelle inondable (PI)

# Analyse d'un trafic réseau (1/4)

## ● Réseau informatique : transfert de paquets



- **Problème** : analyse des paquets perdus sur un sous-réseau
- $X$  : variable aléatoire « nombre de paquets envoyés jusqu'à bonne réception »
- $X$  loi géométrique :  $P(X = n) = (1 - p)^{n-1}p$   
 $p$  : probabilité qu'un paquet soit correctement transmis

- observation de 7 réalisations de  $X$  :

2	3	8	3	4	7	8
---	---	---	---	---	---	---

Estimation de  $p$  ?

- 1 estimation par ML
- 2 estimation par MAP

## 1 estimation par max de vraisemblance

2	3	8	3	4	7	8
---	---	---	---	---	---	---

● vraisemblance :  $L(\mathbf{x}, \theta) = \prod_{i=1}^7 P(x_i|\theta)$

$\theta$  = estimation de  $p$

● observations  $\Rightarrow L(\mathbf{x}, \theta) = (1 - \theta)^{28} \theta^7$

$$\Rightarrow \ln L(\mathbf{x}, \theta) = 28 \ln(1 - \theta) + 7 \ln \theta$$

$$\Rightarrow \frac{\partial \ln L(\mathbf{x}, \theta)}{\partial \theta} = \frac{-28}{1 - \theta} + \frac{7}{\theta} = \frac{7 - 35\theta}{\theta(1 - \theta)}$$

$$\Rightarrow \text{maximum de vraisemblance} = \theta = 0,2$$

## 2 estimation par max de vraisemblance

2	3	8	3	4	7	8
---	---	---	---	---	---	---

● A priori :  $\pi(\theta) = \text{Beta}(\theta, 2, 15) = \frac{\Gamma(17)}{\Gamma(2)\Gamma(15)}\theta^1(1-\theta)^{14}$

●  $\text{Argmax}_{\theta}\pi(\theta|\mathbf{x}) = \text{Argmax}_{\theta}L(\mathbf{x}, \theta)\pi(\theta)$

$$= \text{Argmax}_{\theta}[(1-\theta)^{28}\theta^7] \times [(1-\theta)^{14}\theta]$$
$$= \text{Argmax}_{\theta}(1-\theta)^{42}\theta^8$$
$$= \text{Argmax}_{\theta} 42 \ln(1-\theta) + 8 \ln \theta$$

$$\Rightarrow \theta_{MAP} = 0,16$$