

MAPSI — cours 6 : Chaîne de Markov

Nicolas Thome
nicolas.thome@isir.upmc.fr

LIP6 / ISIR – Sorbonne Université, France

- Les problèmes traités jusqu'ici :

$$X = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1d} \\ \vdots & & & \\ X_{N1} & X_{N2} & \cdots & X_{Nd} \end{bmatrix}, \text{ et parfois : } Y = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}$$

- Chaque individu $\mathbf{x} = [x_1, x_2, \dots, x_d]$ est un vecteur i.i.d.
- **Les séquences** ne rentrent pas dans ce cadre

Traitement des séquences

Tâches :


- Classification / Clustering
- Etiquetage / Segmentation
- Génération de séquences
- Modélisation de la diffusion
- Reconnaissance de chaîne de caractères



Traitement des séquences

Tâches :

- Classification / Clustering
- Etiquetage / Segmentation
- Génération de séquences
- Modélisation de la diffusion
- Reconnaissance de paroles



Traitement des séquences

Tâches :

- Classification / Clustering
- Etiquetage / Segmentation
- Génération de séquences
- Modélisation de la diffusion
- Reconnaissance de mouvements



Traitement des séquences


Tâches :

- Classification / Clustering
- Etiquetage / Segmentation
- Génération de séquences
- Modélisation de la diffusion
- Génération de mouvements

Traitement des séquences

Tâches :


- Classification / Clustering
- Etiquetage / Segmentation
- Diffusion dans les graphes
- Génération de séquences
- Modélisation de la diffusion



Traitement des séquences

Tâches :


- Classification / Clustering
- Etiquetage / Segmentation
- Diffusion dans les graphes
- Génération de séquences
- Modélisation de la diffusion



Traitement des séquences

Tâches :

- Classification / Clustering
- Etiquetage / Segmentation
- Diffusion dans les graphes
- Génération de séquences
- Modélisation de la diffusion




Approche générative

Problème

- Méthodes standards de classification/clustering \Rightarrow transition difficile vers les **données de taille variable**
- \Rightarrow modèles génératifs de séquences (de taille variable)

Approche vectorielle : $X = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1d} \\ \vdots & & & \\ X_{N1} & X_{N2} & \cdots & X_{Nd} \end{bmatrix}$

Approche séquentielle :



Modèles génératifs

Nicolas Thome
`nicolas.thome@isir.upmc.fr`

LIP6 / ISIR – Sorbonne Université, France

Rappel sur les modèles génératifs

- ➊ Choix d'une modélisation des données : $p(\mathbf{x}|\theta)$
- ➋ Apprentissage = trouver θ
- ➌ Application possible : décision bayesienne


$$r(\mathbf{x}) = \arg \max_k p(\theta_k | \mathbf{x}) = \frac{p(\mathbf{x} | \theta_k) p(\theta_k)}{p(\mathbf{x})}$$

- ➍ Application bis : génération de $\tilde{\mathbf{x}} \sim \mathcal{D}(\theta_k)$

Apprentissage d'un modèle génératif \Leftrightarrow Estimation de densité


- ➎ Estimer θ_k = estimer une densité de probabilité d'une classe
- ➏ Hypothèse (forte) : les θ_k sont supposés indépendants
- ➐ Techniques d'estimation des θ_k

1 Schéma général du maximum de vraisemblance :




- 2 Inférence au sens du max de vraisemblance
- 3 Prise en compte des a priori
- 4 Génération

- 1 Schéma général du maximum de vraisemblance :
- 2 Inférence au sens du max de vraisemblance




- 3 Prise en compte des a priori
- 4 Génération

- ➊ Schéma général du maximum de vraisemblance :
- ➋ Inférence au sens du max de vraisemblance
- ➌ Prise en compte des a priori



- ➍ Génération

- ➊ Schéma général du maximum de vraisemblance :
- ➋ Inférence au sens du max de vraisemblance
- ➌ Prise en compte des a priori
- ➍ Génération



Maximum de vraisemblance (données vec.)

- $D = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ exemples supposés générés par $p(\mathbf{x}|\theta)$
- Adéquation entre les données et le modèle
 - Notion de vraisemblance des observations
 - Hyp : les données sont indépendantes

$$\mathcal{L}(D, \theta) = p(D|\theta) = \prod_{i=1}^N p(\mathbf{x}_i|\theta)$$

- Optimisation :

$$\theta^* = \arg \max_{\theta} (\mathcal{L}(D, \theta)) = \arg \max_{\theta} (\log \mathcal{L}(D, \theta))$$

- Résolution :
 - Analytique : $\frac{\partial \mathcal{L}(D, \theta)}{\partial \theta} = 0$
 - Approchée : EM, gradient...

Traitement des séquences

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les \mathbf{x}_i
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Catégorisation (non-supervisée)
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...

Traitement des séquences

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les \mathbf{x}_i
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Vraisemblance : $\log \mathcal{L} = \sum_i \log (p(\mathbf{x}_i | \lambda))$ [classique]
 - Catégorisation (non-supervisée)
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...

Traitement des séquences

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les \mathbf{x}_i
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Vraisemblance : $\log \mathcal{L} = \sum_i \log(p(\mathbf{x}_i | \lambda))$ [classique]
 - Apprentissage : $\lambda^* = \text{Argmax}_{\lambda} \log \mathcal{L}$ [classique]
 - Catégorisation (non-supervisée)
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...

Traitement des séquences

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les \mathbf{x}_i
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Vraisemblance : $\log \mathcal{L} = \sum_i \log(p(\mathbf{x}_i | \lambda))$ [classique]
 - Apprentissage : $\lambda^* = \text{Argmax}_{\lambda} \log \mathcal{L}$ [classique]
 - Inférence : $c^* = \text{Argmax}_c p(\mathbf{x}_i | \lambda_c^*)$ [classique]
 - Catégorisation (non-supervisée)
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...

Traitement des séquences

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les \mathbf{x}_i
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Vraisemblance : $\log \mathcal{L} = \sum_i \log(p(\mathbf{x}_i | \lambda))$ [classique]
 - Apprentissage : $\lambda^* = \text{Argmax}_{\lambda} \log \mathcal{L}$ [classique]
 - Inférence : $c^* = \text{Argmax}_c p(\mathbf{x}_i | \lambda_c^*)$ [classique]
 - Catégorisation (non-supervisée)
 - ... idem + bouclage EM [classique]
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...

Traitement des séquences

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les \mathbf{x}_i
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Vraisemblance : $\log \mathcal{L} = \sum_i \log(p(\mathbf{x}_i | \lambda))$ [classique]
 - Apprentissage : $\lambda^* = \text{Argmax}_{\lambda} \log \mathcal{L}$ [classique]
 - Inférence : $c^* = \text{Argmax}_c p(\mathbf{x}_i | \lambda_c^*)$ [classique]
 - Catégorisation (non-supervisée)
 - ... idem + bouclage EM [classique]
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...
 - ... prochaine séance, modèle plus compliqué

- Outil pour faire de la prévision dans des **espaces discrets**
- Chaîne de Markov d'ordre k
 - Séquence de variables aléatoires $\mathbf{x} = (x_1, \dots, x_T)$ qui prend ses valeurs dans un ensemble fini d'états $Q = (q_1, \dots, q_N)$ et qui vérifie les propriétés dites de Markov :
 - **Chaîne de Markov d'ordre k** (horizon) :
- $p(x_{t+1} = q_j | x_1, \dots, x_t) = p(x_{t+1} = q_j | x_{t-k+1}, \dots, x_t)$
 - Dans la suite : chaînes d'ordre 1.
- Exemple : météo sur un an (soleil, nuage, pluie)
 - $Q = [\text{So}, \text{Nu}, \text{Pl}]$
 - $\mathbf{x} = [x_1 = \text{Nu}, x_2 = \text{So}, \dots, x_{365} = \text{Pl}]$

Soit un exemple très simple :

- $Q = [\textcolor{orange}{So}, \textcolor{gray}{Nu}, \textcolor{blue}{Pi}]$
- $\mathbf{x} = [x_1 = \textcolor{gray}{Nu}, x_2 = \textcolor{orange}{So}, \dots, x_{365} = \textcolor{blue}{Pi}]$
- Combien de paramètres pour une chaîne d'ordre 1 ?

Soit un exemple très simple :

- $Q = [\textcolor{orange}{So}, \textcolor{gray}{Nu}, \textcolor{blue}{Pi}]$
- $\mathbf{x} = [x_1 = \textcolor{gray}{Nu}, x_2 = \textcolor{orange}{So}, \dots, x_{365} = \textcolor{blue}{Pi}]$
- Combien de paramètres pour une chaîne d'ordre 1 ?
- Combien de paramètres pour une chaîne d'ordre 2 ?

9 (+3)

27 (+3)

- Une chaîne de Markov d'ordre 1 est entièrement spécifiée par la donnée :

- d'une matrice de transition


$$\mathbf{A} = [a_{ij} = p(x_{t+1} = q_j | x_t = q_i)]$$

- et des probabilités initiales :

$$\Pi = [\pi_i = p(x_1 = q_i)]$$

- Probabilité d'une séquence

$$p(\mathbf{x}|\lambda) = p(x_1, \dots, x_T|\lambda)$$



Hypothèse markovienne d'ordre 1

Décomposition du calcul

$$\begin{aligned} p(\mathbf{x}|\lambda) &= p(x_1, \dots, x_T|\lambda) \\ &= p(x_T|x_1, \dots, x_{T-1}, \lambda) \times p(x_1, \dots, x_{T-1}|\lambda) \\ &= p(x_T|x_1, \dots, x_{T-1}, \lambda) \times p(x_{T-1}|x_1, \dots, x_{T-2}, \lambda) \dots \\ &\quad \times p(x_1, \dots, x_{T-2}|\lambda) \\ &= \prod_{t=2}^T p(x_t|x_1, \dots, x_{t-1}, \lambda) p(x_1|\lambda) \end{aligned}$$

Après hypothèse d'ordre 1 :

$$\begin{aligned} p(\mathbf{x}|\lambda) &= \prod_{t=2}^T p(x_t|x_1, \dots, x_{t-1}, \lambda) p(x_1|\lambda) = \prod_{t=2}^T p(x_t|x_{t-1}, \lambda) p(x_1|\lambda) \\ &= \pi_{x_1} \prod_{t=2}^T a_{x_{t-1}, x_t} \end{aligned}$$

- Matrice de transition \mathbf{A} de taille $N \times N$
 - Lignes \mathbf{x}_t , colonnes \mathbf{x}_{t+1}
 - Matrice stochastique, chaque ligne somme à 1 : $\sum_{j=1}^N a_{ij} = 1$


- Matrice de transition \mathbf{A} de taille $N \times N$
 - Lignes \mathbf{x}_t , colonnes \mathbf{x}_{t+1}
 - Matrice stochastique, chaque ligne somme à 1
- $\mathbf{p}_t := p(x_t = q_i | x_1, \dots, x_{t-1}, \lambda), \forall i \in \{1; N\}$
 - \mathbf{p}_t vecteur ligne, taille $1 \times N$
- $\mathbf{p}_{t+1} := p(x_{t+1} = q_i | x_1, \dots, x_t, \lambda), \forall i \in \{1; N\}$
 - \mathbf{p}_{t+1} vecteur ligne, taille $1 \times N$

Représentation matricielle

- Matrice de transition \mathbf{A} de taille $N \times N$
- $\mathbf{p}_t / \mathbf{p}_{t+1}$ vecteurs de probabilité à $t / t + 1$
- Treillis pour calculer le vecteur de probabilité $\mathbf{p}_{t+1} \forall j \in \{1; N\}$

$$\bullet p(x_{t+1} = q_j) = \sum_{i=1}^N p(x_t = q_i)p(x_{t+1} = q_j | x_t = q_i) = \sum_{i=1}^N p(x_t = q_i) a_{ij}$$

$$\mathbf{p}_{t+1} = \mathbf{p}_t \times \mathbf{A}$$



Représentation matricielle : exemple

Il fait soleil... Quel temps fera-t-il dans N jours ? (distribution de probabilités)

Il fait soleil... Quel temps fera-t-il dans N jours ? (distribution de probabilités)


- ➊ Je rentre sur la ligne *soleil*... $x_0 = S$
- ➋ A $t = 1$, $\{a_{x\cdot}\}$ me donne la distribution des probabilités des états
 $p(x_1 = q_i) = a_{S,i} \Rightarrow \mathbf{p}_1 = \{a_{S,i}\}_{i \in \{1;N\}}$

Il fait soleil... Quel temps fera-t-il dans N jours ? (distribution de probabilités)

- ➊ Je rentre sur la ligne *soleil*... $x_0 = S$
- ➋ A $t = 1$, $\{a_{x_i}\}$ me donne la distribution des probabilités des états
 $p(x_1 = q_i) = a_{S,i} \Rightarrow \mathbf{p}_1 = \{a_{S,i}\}_{i \in \{1;N\}}$
- ➌ Ensuite on itère :
 - $\mathbf{p}_2 = \mathbf{p}_1 \times \mathbf{A}$
 - $\mathbf{p}_N = \mathbf{p}_1 \times \mathbf{A}^{N-1}$


Représentation graphique

Automate basique :




Représentation graphique

Comment introduire la notion de commencement ?



Représentation graphique

Avec des noeuds identifiés de début/fin



Algorithm 1: Génération d'une séquence \mathbf{x}

Data: A, Π

Result: \mathbf{x}

$\mathbf{x} \leftarrow [];$

Tirer x_1 en fonction de Π ;

$x_t \leftarrow x_1, t \leftarrow 1;$

$\mathbf{x} \leftarrow [\mathbf{x}, x_{courant}]$;

while x_t n'est pas l'état final **do**

$x_{t+1} \leftarrow$ tirage selon $(A(x_t, :))$;

$t \leftarrow t + 1$;

- Plusieurs variantes dans la clause du *while*
- Comment effectuer un tirage selon une loi de probabilité discrète ?

Soit la loi :

A	1	2	3
$P(A)$	0.3	0.2	0.5

Comment effectuer un tirage selon $P(A)$?

- ➊ Faire la somme cumulée de la loi

A	1	2	3
<i>cumsum</i>	0.3	0.5	1


- ➋ Tirer un nombre x entre 0 et 1 selon la loi uniforme
- ➌ Initialiser $vx = 1$
- ➍ Tant que $cumsum[vx] < x$
 - ➎ $vx++$

Génération (sur un exemple)

- $q_1 = \text{Pluie}$, $q_2 = \text{Nuages}$, $q_3 = \text{Soleil}$

- $A =$

0.1	0.1	0.8
0.1	0.15	0.75
0.05	0.05	0.9



PSSSSSSSSSSSSNSSSSSSSSSSNSSSSSSNSSSSNSS

SSSSSSSSSSSSSSPSSSSSNPSSSSSPNSSSSSNNSSS

SSSSPSSSSSSSSSSPSSSSSSSSSSSSSSPSSSSSSSSSS

- Quelle est la probabilité d'observer une séquence de soleil de longueur d ? [en se trouvant au premier jour de soleil]
- Quelle est la durée moyenne d'une séquence consécutive de soleil ?

- Quelle est la probabilité d'observer une séquence de soleil de longueur d ? [en se trouvant au premier jour de soleil]
- Quelle est la durée moyenne d'une séquence consécutive de soleil ?

Quelle est la probabilité d'observer une séquence de soleil de longueur d (étant donné que l'on se trouve au premier jour de soleil) ?

Loi géométrique

Notons la longueur de la sous-séquence de soleil D_S ,

$$P(D_S = d) = a_{ss}^{d-1}(1 - a_{ss})$$

- Quelle est la probabilité d'observer une séquence de soleil de longueur d ? [en se trouvant au premier jour de soleil]
- Quelle est la durée moyenne d'une séquence consécutive de soleil ?

Quelle est la longueur moyenne d'une séquence de soleil ?

Espérance de la loi géométrique

$$E[D_S] = \sum_{d=1}^{\infty} d a_{ss}^{d-1} (1 - a_{ss}) = \frac{1}{1 - a_{ss}}$$

- Quelle est la probabilité d'observer une séquence de soleil de longueur d ? [en se trouvant au premier jour de soleil]
- Quelle est la durée moyenne d'une séquence consécutive de soleil ?

Quelle est la longueur moyenne d'une séquence de soleil ?

Espérance de la loi géométrique

$$E[D_S] = \sum_{d=1}^{\infty} d a_{ss}^{d-1} (1 - a_{ss}) = \frac{1}{1 - a_{ss}}$$

Sketch of proof (voir TD) avec $k = d - 1$ et $p = 1 - a_{ss}$:

$$\begin{aligned} E(Y) &= \sum_{k=0}^{\infty} (1-p)^k p \cdot (k+1) \\ &= p \sum_{k=0}^{\infty} (1-p)^k (k+1) \\ &= p \left[\frac{d}{dp} \left(-(1-p) \sum_{k=0}^{\infty} (1-p)^k \right) \right] \\ &= -p \frac{d}{dp} \frac{1-p}{p} = \frac{1}{p}. \end{aligned}$$

Stationnarité : CM converge-t-elle \rightarrow mesure stationnaire μ ?

- **Point fixe**, proba des états ne change plus au cours du temps
 - $\mu = \text{pondération stationnaire}$ (inchangée après une transition)

$$\mu = \mu \mathbf{A}$$

- si $\forall i, \mu_i \geq 0, \sum_i \mu_i = 1$: μ est alors une **distribution stationnaire**
 - Distribution moyenne des états
- CM : paramètres $\lambda := (\mathbf{A}, \Pi)$
- Existence : conditions pour que la CM converge (ou pas)
- Unicité : point fixe unique (indépendant de Π)

$$\mu = \mu \mathbf{A}$$

- Stationnarité : $\mu^T = \mathbf{A}^T \mu^T$
- **Condition nécessaire :** Solution donnée par le sous-espace propre (SEP) associé à la de valeur propre 1 de \mathbf{A}^T
 - 1 est valeur propre (VP) de \mathbf{A}^T car 1 est VP de \mathbf{A} (\mathbf{A}^T et \mathbf{A} ont même VPs). \mathbf{A} est une matrice stochastique $\rightarrow (1, \dots, 1)$ vecteur propre associé à VP 1.
- **Condition suffisante ?**
 - ① SEP de dimension 1, et vecteur propre proba : solution unique
 - ② SEP de dimension >1 : solution non unique



Quel condition sur la CM pour que 1 soit vérifiée ?

Irréductibilité des CM


CM irreducible

- **CM irréductible** : chaque état est accessible à partir de chaque autre état.
- Graphe G de la CM fortement connexe, pas d'état final/absorbant
- **Chaîne réductible** : plusieurs composantes du graphe

CM irréductible



CM réductible




	1	3	4	5	2
1	0, 5	0, 5	0	0	0
3	0, 4	0, 6	0	0	0
4	0	0	0, 1	0, 9	0
5	0	0	0, 5	0, 5	0
2	0, 25	0, 25	0	0	0, 5

Périodicité

- Période d'un état : PGCD des longueurs des cycles
 - Longueur cycle : temps n pour revenir dans un état,
 $P(X_n = i | X_0 = i) > 0$
- Période CM : PGCD de la période de tous ses états
 - Période $k > 1$: chaîne périodique
 - Période $k = 1$: chaîne apériodique
- Propriété : états de chaque composante CM ont même période

Périodicité des CM : exemples

CM irréductible apériodique




Etat 0 : PGCD(3,4)=1

Etats 1-3 : PGCD(4,7)=1

Etat 4-5 : PGCD(3,7)=1

CM irréductible périodique



Période = 2

Un processus ergodique est un processus stochastique pour lequel les statistiques peuvent être approchées par l'étude d'une seule réalisation suffisamment longue.

- Une chaîne de Markov est ergodique si π_n converge, indépendamment de π_0 .
- π_n converge alors vers π^* , la distribution stationnaire.
- L'espace propre associé à la VP 1 de \mathbf{A}^T dimension 1


Théorème

Les chaines **irréductible** et **apériodique** sont **ergodiques**

- Dans ce cas :
$$\mathbf{A}^\infty = (\Pi_1, \dots, \Pi_k, \dots, \Pi_N), \text{ avec } \Pi_k = (\Pi_{k,1}, \dots, \Pi_{k,N}) \in \mathbb{R}^{N \times N}$$
- et $\forall \mathbf{x}$ tq $\sum_{i=1}^N x_i = 1$, $\mathbf{x}\mathbf{A}^\infty = (\Pi_1, \dots, \Pi_N)$ (convergence vers Π)

Convergence des CM : exemple 1


CM irréductible apériodique
⇒ ergodique



Etat 0 : PGCD(3,4)=1
Etats 1-3 : PGCD(4,7)=1
Etat 4-5 : PGCD(3,7)=1

⇒ Convergence

CM irréductible périodique
⇒ non ergodique




Période = 2
Sûr $\neq (2, 4, 6)$ pour n pair
Sûr $\neq (3, 5, 7)$ pour n impair

⇒ Pas de convergence

Convergence des CM : exemple 2


CM irréductible apériodique
⇒ **ergodique**



1 VP de \mathbf{A}^T

⇒ **Convergence**
indépendante de Π

CM réductible apériodique
⇒ **non ergodique**




2 VPs de \mathbf{A}^T



⇒ **Convergence**
dépendante de Π

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :





$t = 0$

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :





$t = 1$

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :





$t = 2$

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :





$t = 3$

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :





$t = 4$

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?



Matrice de transition :






$t = 5$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 0$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 1$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 2$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 3$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 4$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 5$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 6$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 7$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 8$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 9$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 10$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 15$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 20$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 30$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 40$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 50$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 60$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 70$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 80$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 90$

Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 100$


Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 0$



Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 1$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 2$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 3$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 4$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 5$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 6$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 7$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 8$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 9$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 10$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 15$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 20$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 30$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 50$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 50$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 60$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 70$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 80$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :





$t = 90$

Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :






$t = 100$

Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?



Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?





Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?



Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?




Matrice de transition :



Exemples & discussion (4)

CM irréductible ? Apériodique ? Ergodique ?



Matrice de transition :



- Séquence de lancers de pièce(s)...

p_k : probabilité de faire *pile* avec la pièce k

p : probabilité de faire *pile*




- Modélisation de parcours utilisateur sur un site web
 - Catégorisation / publicité personnalisée
 - Optimisation du site / pré-chargement de pages
- 1 trace = longueur variable...

Modélisation (3)

- Modélisation de parcours utilisateur sur un site web
 - Catégorisation / publicité personnalisée
 - Optimisation du site / pré-chargement de pages
- 1 trace = longueur variable...

Modèle

- **Etats :**
page du site
- **Transitions :**
hyperliens



Apprentissage des chaines de Markov

Nicolas Thome
`nicolas.thome@isir.upmc.fr`

LIP6 / ISIR – Sorbonne Université, France

- Etant donnée une séquence d'états, calculer sa probabilité Vu précédemment :

$$\begin{aligned} p(X|\lambda) &= \prod_{t=2}^T p(x_t|x_1, \dots, x_{t-1}, \lambda) p(x_1|\lambda) = \prod_{t=2}^T p(x_t|x_{t-1}, \lambda) p(x_1|\lambda) \\ &= \pi_{x_1} \prod_{t=2}^T a_{x_{t-1}, x_t} \end{aligned}$$

- Comment apprendre une CM à partir d'exemples ?
- Comment faire de la classification de séquences avec des CM ?

- Soit une base de séquences $B = \{X^1, \dots, X^K\}$ (N états possibles)
- Critère de vraisemblance

$$\log \mathcal{L}(B, \lambda) = \log \left(\prod_{k=1}^K p(X^k | \lambda) \right) = \sum_k \log(p(X^k | \lambda))$$

- Optimisation :

$$\lambda^* = \arg \max_{\lambda} \log \mathcal{L}(B, \lambda)$$

- Contraintes :

$$\forall i \in [1, N], \sum_{j=1}^N a_{ij} = 1$$

$$\sum_{j=1}^N \pi_j = 1$$

- Critère intégrant les **contraintes** (Lagrangien) :

$$\mathcal{C}(\lambda) = \mathcal{L}(B, \lambda) - \sum_{i=1}^N \nu_i \left(\sum_{j=1}^N a_{ij} - 1 \right) - \eta \left(\sum_{j=1}^N \pi_j - 1 \right)$$

- Si la dérivée par rapport au coefficient de contrainte est nulle, la contrainte est satisfaite :

$$\frac{\partial \mathcal{C}(\lambda)}{\partial \eta} = 0 \Leftrightarrow \sum_{j=1}^N \pi_j - 1 = 0$$

- Ecriture du Maximum de Vraisemblance :

$$L(B, \lambda) = \prod_{k=1}^K p(X^k | \lambda) = \prod_{k=1}^K \pi_{x_1^k} \prod_{t=2}^T a_{x_{t-1}^k, x_t^k}$$
$$L(B, \lambda) = \prod_{i=1}^N \pi_i^{l_i} \prod_{j=1}^N a_{ij}^{n_{ij}}$$

(1)

- n_{ij} # transitions (ij) observées, l_i # état initiaux i observés
- $\ell = \log(L(B, \lambda)) = \sum_{i=1}^N \left[l_i \log(p_i) + \sum_{j=1}^N n_{ij} \log(a_{ij}) \right]$
- Résolution : $\frac{\partial \ell}{\partial a_{ij}} = 0$, $\frac{\partial \ell}{\partial \pi_i} = 0$ + contraintes :

$$a_{ij} = \frac{n_{ij}}{n_{i \cdot}} \quad \pi_j = \frac{l_j}{K}, \text{ avec : } n_{i \cdot} = \sum_j n_{ij}$$

- Approche par comptage
- Calcul des fréquences des évènements = solution au sens MV
- Chaque ligne de A est une distribution (sommant à 1)
- En faisant une hypothèse de stationnarité (ergodicité), il est possible d'estimer les π_j sur toute la base de données :

$$\text{classique : } \pi_j = \frac{I_j}{K} \quad \text{alternative stationnaire : } \pi_j = \frac{n.j}{\sum_{ij} n_{ij}}$$

Distance entre séquences

Nicolas Thome
`nicolas.thome@isir.upmc.fr`

LIP6 / ISIR – Sorbonne Université, France

- Similarité/distance = outil de base
 - k-plus proches voisins...
- La similarité peut concerner une partie seulement du signal
 - Reflexion sur les besoins spécifiques


Dynamic Time Warping (DTW)

- L'analyse du signal est locale (cf. stationnarité)
- Unités de reconnaissance plus globales (phonèmes, mots, ...)
- ⇒ Nécessité de comparer des séquences de vecteurs
- **DTW = distance entre séquences**
 - ayant des longueurs différentes
 - insensible à certaines variabilités d'élocution
 - calculable efficacement

Distance entre séquences

Idée :


- Existence d'une distance entre séquences capable de
 - Prendre en compte les différences de rythme dans les séquences
 - Comparer des séquences de longueur différente
- Dynamic Time Warping (DTW)



La distance entre les séquences est la somme des distances entre éléments mis en correspondance par l'alignement

Appariement avec contraintes

- Continuité locale
- Alignement quasi linéaire
- Début et fin synchrones



Distance entre séquences (2)

Notion de chemin d'alignement :

- Chemin : $c = \{(i_k, j_k)\}_{k=1, \dots, K}$ tel que :

$$\forall k, (i_k, j_k) = \begin{cases} (i_{k-1} - 1, j_{k-1}) & i_1 = j_1 = 1 \\ (i_{k-1} - 1, j_{k-1} - 1) & j_K = T_2 \\ (i_{k-1}, j_{k-1} - 1) & i_K = T_1 \end{cases}$$

- Distance suivant un alignement :

$$D_c(S_1, S_2) = \sum_{k=1}^K d_{c(k)}(S_1[i(k)], S_2[j(k)])$$

- Distance entre 2 séquences

$$D(S_1, S_2) = \min_c D_c(S_1, S_2)$$

Distance entre séquences (3)

Phase avant :

- calcul des $\forall i, j, d(S_1[i], S_2[j])$
- sommes cumulées

3	2	5	2	4	2	2
2	2	3	2	1	4	4
2	1	2	2	2	3	4
1	1	2	1	1	3	2
1	1	3	3	3	3	4

2							
1							

3							
2							
3	3	4					
2	2	2	4				
1	2	5					

9	7	10	8	10	9	11	
6	5	6	6	7	11	13	
4	3	4	6	7	9	13	
2	2	4	5	6	9	11	
1	2	5	8	11	14	18	

Distance entre séquences (4)

Phase retour :

- Chemin correspondant au cout minimum

9	7	10	8	10	9	11	
6	5	6	6	7	11	13	
4	3	4	6	7	9	13	
2	2	4	5	6	9	11	
1	2	5	8	11	14	18	

The diagram shows a grid of numbers with arrows indicating a path from the bottom-left cell (1) to the top-right cell (11). The path follows a sequence of moves: right, up-right, up-right.

Distance entre séquences (5)

3	2	5	2	4	2	2
2	2	3	2	1	4	4
2	1	2	2	2	3	4
1	1	2	1	1	3	2
1	1	3	3	3	3	4

3	2	5	2	4		
2	2	3	2	1		
1	2	5				
1	2	5				

2	2					
1	2					

Phase avant

9	7	10	8	10	9	11
6	5	6	6	7	11	13
4	3	4	6	7	9	13
2	2	4	5	6	9	11
1	2	5	8	11	14	18

Phase arrière

9	7	10	8	10	9	11
6	5	6	6	7	11	13
4	3	4	6	7	9	13
2	2	4	5	6	9	11
1	2	5	8	11	14	18

Alignement final et distance

x_5	3	2	5	2	4	2	2
x_4	2	2	3	2	1	4	4
x_3	2	1	2	2	2	3	4
x_2	1	1	2	1	1	3	2
x_1	1	1	3	3	3	3	4
	y_1	y_2	y_3	y_4	y_5	y_6	y_7